

小学数学题求解实验报告

模型：Qwen2.5-0.5B-Instruct；主要训练方式：LoRA SFT；最终提交：cot4-clean007008010-dpo66-vote.csv。
郑智君 23307130062

一、实验目的

本实验的任务是让一个 0.5B 规模的开源模型解小学数学题，并输出可以提交到 DataFountain 的最终答案。题目看起来短，但坑不少：分数、小数、百分数、单位换算、几何、多步应用题都会影响答案抽取。所以实验目标不是只把训练跑通，而是做一个完整闭环：先把数据洗干净，再让模型学会“算过程”，最后用多个模型结果互相补位。整个过程中重点保证训练集和验证集不泄漏，避免本地分数虚高。

二、实验方法

方法	具体做法	作用
数据构建	清洗题面和答案，按清洗后的题面分组切分 valid_v2；训练 10902 条，验证 1000 条，同题 overlap 为 0	让验证分数更可信
数据增强	clean-008 复制弱答案类型、比例速度、单位换算题；clean-010 重点复制几何题	补模型薄弱题型
CoT	用 DeepSeek 生成可接受的推理过程，训练模型输出“推理 + 最终答案”	让模型少直接猜，多做中间计算
DPO	accepted CoT 作为 chosen，cot-001 错误生成作为 rejected，共构造 4161 对偏好样本	让模型偏向更稳的解题表达
模型投票	CoT 多 checkpoint 投票，再加入 clean 系列和 DPO 结果做八源投票	利用不同模型的互补性

核心思路其实比较朴素：先把“答案到底是什么”这件事做准，再谈训练。小学数学题里经常出现 1/2、50%、0.5 这类等价但格式不同的答案，所以代码里先用 answer_utils 统一抽取、规范化和比较答案。验证集也不是随机切，而是按清洗后的题面分组切分；这样同一道题的改写不会一边进训练、一边进验证，本地分数才不容易自我安慰。

CoT 的设计也尽量克制。模型可以写推理，但最后必须单独写 最终答案：<答案>，推理正文里的中间数字不参与提交答案抽取。DPO 则接在 CoT 后面做：accepted CoT 当作 chosen，模型自己在训练集上生成错的回答当作 rejected。这样 preference pair 更贴近当前模型真的会犯的错，而不是随便拼一个负样本。投票阶段也没有对文本做平均，而是先把每一路 raw 结果里的答案规范化，再按 majority vote 选答案；平票时才按 source 顺序回退。

实现上还刻意把训练、推理、评估拆开。训练脚本只负责产出 checkpoint，不直接相信 eval_loss；推理脚本保存每题原始输出；评估脚本再根据生成答案算准确率、保存错题和归因。这样每次提交前都能追到“这个答案从哪个模型来、为什么被选中”，后面做投票和 DPO 时也省了很多返工。

Valid_v2 method comparison

Same no-leak validation split; higher is better




图 1. valid_v2 上的主要方法对比。CoT 是最大拐点，投票继续补上不少题。

DataFountain score timeline

Public score after each major method change




图 2. DataFountain 分数走势。最终八源投票达到 0.252375。

三、实验过程

整个实验不是一次性把参数调出来的，而是一个很典型的循环：先跑一个能提交的版本，发现分数和错题问题，再补工具链；之后每轮都看 valid_v2、raw 输出和 wrong 分析，再决定下一步是改数据、改 prompt，还是做组合。这样虽然慢一点，但每次改动都有原因，不至于只靠碰运气。

阶段	为什么改	做了什么	结果和下一步
baseline	先建立可跑通的起点	用原始数据做 LoRA SFT，直接生成答案	DF 0.140125。能跑通，但模型容易格式乱、直接猜。下一步先修工具链和数据
数据清洗	原始数据有噪声，旧验证集也可能不够可靠	做答案规范化、题面清洗、冲突样本剔除；answer_utils 负责抽取和比较答案	clean-001-final DF 到 0.140250，提升很小。说明只清洗还不够
valid_v2	需要一个更可信的本地验证集	按清洗题面分组切分；evaluation 保存 metrics、raw、wrong 和 wrong_analysis	train/valid overlap 为 0。后续本地结果统一看 valid_v2
clean-007	直接答案模型可能被截断	把 max_length 从 384 提到 512	valid_v2 358/1000，DF 0.140875。比清洗版稳一点，但上限仍低
clean-008/010	小数、分数、单位、几何题明显偏弱	clean-008 新增 2794 条增强样本；clean-010 新增 1248 条几何样本	单模型没有明显超过 clean-007，但给后面的异质投票提供了不同答案来源
三源组合	不同增强数据会错在不同题上	用 clean-007/008/010 的 raw 结果做题面 selector 组合	valid_v2 374/1000，本地有提升；DF 0.140750 略降，说明简单路由还不够稳
CoT SFT	直接给答案太像“猜数”，数学题需要中间过程	用 DeepSeek 生成 accepted CoT，训练 cot-001，答案从“最终答案：”后抽取	valid_v2 544/1000，DF 0.228375。这是最大提升，下一步尝试多 checkpoint 互补
CoT 投票	单 checkpoint 有波动，多个 checkpoint 会犯不同错	ensemble/voting 读取四路 raw，先规范化答案，再 majority vote	valid_v2 577/1000，DF 0.244375。比单模型多对 33 题
异质投票	clean 模型虽然弱，但可能在少数题上给出不同正确答案	CoT top4 + clean-007/008/010 七源投票，保留 source provenance	valid_v2 612/1000，DF 0.252125。说明“弱模型”也能补洞
DPO	希望模型更偏向正确推理，而不是只靠投票	accepted CoT 做 chosen，cot-001 训练集错误生成做 rejected，训练 2 epochs	DPO 单模型 valid_v2 559/1000，DF 0.230250。加入八源投票后 DF 到 0.252375，但 valid_v2 从 0.612 降到 0.607，泛化还不够稳




图 3. 多个 checkpoint 的验证准确率。CoT 与 DPO 明显高于 direct clean 模型。




图 4. 八源投票拆解。多数题仍跟 cot2000 一致；投票改对 70 题，也改错 7 题。

四、实验结果

这里把两类结果分开看：DataFountain 是最终提交分数；valid_v2 是本地无泄漏验证集。base-001 的本地指标来自旧 valid_sft_v1，不和 valid_v2 直接横向比较。

实验	valid_v2	DataFountain	说明
clean-007	0.358	0.140875	direct SFT 中较好的单模型
clean 三源组合	0.374	0.140750	本地提升，线上略降
cot-001	0.544	0.228375	CoT 带来主要提升
cot-001-vote-top4	0.577	0.244375	多 checkpoint 投票有效
cot4-clean007008010-vote	0.612	0.252125	七源异质投票，本地最高
dpo-cot001-best	0.559	0.230250	DPO 单模型略高于 CoT 单模型
cot4-clean007008010-dpo66-vote	0.607	0.252375	最终提交，线上最高

从结果看，clean 系列主要是在“流程稳定”和“提供异质答案”上有价值，单独靠 direct SFT 很难突破。真正的拐点是 CoT：它不是简单让输出变长，而是逼模型先把条件关系写出来，最后再收束到一个答案。DPO 的情况更微妙，单模型比 cot-001 好，但放进投票后 valid_v2 反而从 0.612 降到 0.607；这说明偏好学习确实改了模型习惯，但 rejected 样本还不够细，可能把一部分本来正确的解题风格也扰动了。




图 5. 最终 DataFountain 提交结果截图，最终分数为 0.252375。

最终结果可以概括成一句话：数据清洗让流程稳定，CoT 真正拉高上限，投票把不同 checkpoint 和不同数据版本的优势拼起来。DPO 有单模型收益，但加入投票后本地没有继续涨，说明偏好数据还需要更细地筛。

五、实验展望

后续最值得做的不是盲目再训练，而是把错题用起来。

- 1 继续按错题类型补 CoT。现在已经有 `wrong_analysis.json(l)`，可以统计分数、比例、几何、单位换算分别错在哪里，再针对性生成新的 CoT 数据。
- 2 改进投票策略。当前平票主要按 source 顺序回退，比较粗。后面可以按题型选择可信模型，比如几何题更信 clean-010 或专门几何模型，分数题更信 CoT。
- 3 重做 DPO 的 rejected。现在 rejected 主要来自 cot-001 的错误生成，质量不均匀。可以把“答案错但过程像对的”“答案格式错”“中间计算错”分开构造，减少 DPO 学偏。
- 4 增加自动回流。评估后自动把高置信错题、投票分歧题、后处理失败题打包成下一轮数据构建输入，让实验从手动调参变成稳定迭代。